4 Astuces de Machine Learning

4.1 Indicateurs dans le contexte de la classification

Dans le contexte de la classification binaire, voici les principaux indicateurs à surveiller pour évaluer la performance d'un modèle.

 \square Matrice de confusion – Une matrice de confusion est utilisée pour avoir une image complète de la performance d'un modèle. Elle est définie de la manière suivante :

		Classe prédite		
		+		
Classe vraie	+	TP True Positives	FN False Negatives Type II error	
	-	FP False Positives Type I error	TN True Negatives	

 $\hfill \Box$ Indicateurs principaux – Les indicateurs suivants sont communément utilisés pour évaluer la performance des modèles de classification :

Indicateur	Formule	Interprétation
Accuracy	$\frac{\mathrm{TP} + \mathrm{TN}}{\mathrm{TP} + \mathrm{TN} + \mathrm{FP} + \mathrm{FN}}$	Performance globale du modèle
Precision	$\frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FP}}$	À quel point les prédictions positives sont précises
Recall Sensitivity	$\frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$	Couverture des observations vraiment positives
Specificity	$\frac{\mathrm{TN}}{\mathrm{TN} + \mathrm{FP}}$	Couverture des observations vraiment négatives
F1 score	$\frac{2\mathrm{TP}}{2\mathrm{TP} + \mathrm{FP} + \mathrm{FN}}$	Indicateur hybride pour les classes non-balancées

 \square Courbe ROC – La fonction d'efficacité du récepteur, plus fréquemment appelée courbe ROC (de l'anglais Receiver Operating Curve), est une courbe représentant le taux de True Positives en fonction de taux de False Positives et obtenue en faisant varier le seuil. Ces indicateurs sont résumés dans le tableau suivant :

Indicateur	Formule	Equivalent
True Positive Rate TPR	$\frac{\mathrm{TP}}{\mathrm{TP} + \mathrm{FN}}$	Recall, sensitivity
False Positive Rate FPR	$\frac{\mathrm{FP}}{\mathrm{TN} + \mathrm{FP}}$	1-specificity